



Algoritmo para la detección de enfermedades respiratorias

Tuberculosis, COVID-19 y pulmones saludables mediante visión por computadora

Cabrera Coyotzi Kevin Merlin
Luna García Dulce Anahí

Unidad Profesional Interdisciplinaria en Ingeniería Campus Tlaxcala, IPN

4 de noviembre de 2025

- Propuesta de un modelo de visión por computadora para clasificar imágenes de rayos X en tres clases: pulmones sanos, COVID-19 y tuberculosis.
- Uso de *transfer learning* con MobileNetV2 y clasificadores tradicionales (SVC, KNN, Random Forest).
- Validación con datasets públicos de Kaggle.
- Alta precisión diagnóstica y potencial como herramienta de apoyo clínico.

Introducción

- Las enfermedades respiratorias son un reto global para la salud pública.
- COVID-19 y tuberculosis son las más prevalentes.
- Los métodos tradicionales (radiografías y pruebas clínicas) dependen de la interpretación humana.
- El aprendizaje profundo puede detectar patrones complejos en imágenes médicas.

Problemática actual

- Diagnósticos tardíos o erróneos.
- Similitud radiológica entre enfermedades.
- Escasez de herramientas de apoyo automatizadas.

Solución propuesta

- Sistema basado en visión por computadora.
- Clasificación automática de radiografías torácicas en tres clases:
 - Pulmones saludables
 - COVID-19
 - Tuberculosis

Planteamiento del problema

- Las enfermedades respiratorias requieren detección temprana.
- La interpretación humana es limitada por fatiga, experiencia y subjetividad.
- Se necesita un modelo que automatice el diagnóstico con alta precisión.

Justificación

- Escasez de herramientas automatizadas especializadas en enfermedades respiratorias.
- Variabilidad inter-observador en la interpretación de imágenes médicas.
- Necesidad de diagnósticos más rápidos, económicos y accesibles.
- El modelo busca complementar la labor médica, no reemplazarla.

Objetivo general

Desarrollar un modelo de visión computacional basado en CNN para clasificar imágenes pulmonares como sanas, COVID-19 o tuberculosis, mejorando la rapidez y exactitud del diagnóstico clínico.

Objetivos específicos

- ① Recopilar y procesar imágenes médicas públicas (Kaggle).
- ② Preprocesar y segmentar regiones pulmonares.
- ③ Entrenar CNN y extraer características mediante *transfer learning*.
- ④ Aplicar clasificadores SVC, KNN y Random Forest.
- ⑤ Evaluar desempeño con métricas F1-score y recall.

La clasificación automática de imágenes pulmonares en tres clases (sano, COVID-19, tuberculosis) puede lograrse con alta exactitud mediante modelos de visión por computadora basados en CNN, transfer learning y clasificadores tradicionales sobre embeddings extraídos.

Alcances:

- Imágenes de rayos X de tórax.
- Tres clases: sano, COVID-19, tuberculosis.
- Transfer learning y preprocesamiento estándar.
- Evaluación de rendimiento con métricas clásicas.

Limitaciones:

- No incluye otras enfermedades respiratorias.
- Sin validación clínica real.
- Sin certificación médica oficial.
- Dependencia de calidad de datasets públicos.

- Las CNN permiten reconocer patrones en imágenes médicas.
- El *transfer learning* reutiliza redes preentrenadas como MobileNetV2.
- Técnicas como Grad-CAM ayudan a interpretar las decisiones del modelo.

- Modelos CNN aplicados a rayos X torácicos (ChestX-ray8).
- Precisión superior al 96 % en diagnósticos específicos.
- Avances recientes incorporan destilación de conocimiento (Kabir, 2024) y validación multicéntrica (Kaewlek, 2023).

Cronograma




Figura: Cronograma de actividades

Metodología general




Figura: Adquisición y preparación inicial de los datos

Metodología general




Figura: Generación, entrenamiento y predicción del modelo..

Metodología general




Figura: Evaluación y generación final de resultados.


Etapas principales del proceso (1/2)

- ① **Adquisición de datos:** Kaggle (COVID-19, TB, Normal).
- ② **Segmentación manual:** delimitación de la región pulmonar.
- ③ **Preprocesamiento:**
 - Redimensionado a 224x224 px.
 - Escala de grises y normalización Min-Max.

Etapas principales del proceso (2/2)

- ④ **Extracción de características:** MobileNetV2 (*transfer learning*).
- ⑤ **Clasificación:** SVC, KNN, Random Forest.
- ⑥ **Evaluación:** precisión, recall, F1-score.

Ejemplos de imágenes (antes y después de segmentación)



(a) COVID-19




(b) Tuberculosis



(c) Pulmón sano

Figura: Radiografías originales del dataset.

Ejemplos segmentados



(a) COVID-19



(b) Tuberculosis



(c) Pulmón sano

Figura: Imágenes tras segmentación manual.

Ejemplos despues del preprocesamiento



(a) COVID-19



(b) Tuberculosis



(c) Pulmón sano

Figura: Imágenes tras el preprocesamiento.

Resultados preliminares

- Se probaron 2 conjuntos:
 - ① Segmentadas (3,000 imágenes)
 - ② Sin segmentar (12,000 imágenes)
- Modelo base: MobileNetV2 + clasificadores SVC, KNN, RF.
- Métricas: precisión, recall, F1-score.

Desempeño con imágenes segmentadas

- **SVC**: 97.68 % de exactitud.
- **Random Forest**: 97.32 %.
- **KNN**: 94.11 %.

Modelo	Precisión	Recall	F1-Score	Accuracy
SVC	0.98	0.98	0.98	0.9768
Random Forest	0.97	0.97	0.97	0.9732
KNN	0.94	0.94	0.94	0.9411

Graficas




Figura: Resultados en imagenes segmentadas .

Desempeño con imágenes sin segmentar

- **SVC**: 96.26 % de exactitud.
- **KNN**: 92.13 %.
- **Random Forest**: 88.95 %.
- Segmentación mejora significativamente la precisión.

Modelo	Precisión	Recall	F1-Score	Accuracy
SVC	0.96	0.96	0.96	0.9626
Random Forest	0.90	0.88	0.89	0.8895
KNN	0.94	0.91	0.92	0.9213

Graficas




Figura: Resultados en imagenes no segmentadas .

Conclusiones

- La visión por computadora es una herramienta efectiva para diagnosticar enfermedades respiratorias.
- La segmentación manual mejora la precisión del modelo.
- MobileNetV2 + SVC mostró el mejor desempeño.
- En el futuro se explorará interpretabilidad mediante Grad-CAM.



¡Gracias por su atención!