
Algoritmo para la detección de enfermedades respiratorias como tuberculosis, COVID-19 y pulmones saludables, mediante técnicas de visión por computador

Cabrera Coyotzi Kevin Merlin
kcabrerac2200@alumno.ipn.mx

Luna García Dulce Anahí
dlunag2200@alumno.ipn.mx

Unidad Profesional Interdisciplinaria en Ingeniería Campus Tlaxcala, IPN

Abstract

En la actualidad la mayoría de las enfermedades son detectables a través de un diagnóstico oportuno contando con tiempo y recursos para dicho análisis, el propósito de este modelo es brindar una herramienta en el área de la salud. Se lleva a cabo una revisión general de distintos trabajos, estos tienen que ver con la detección de enfermedades torácicas para tener una visión del cómo son los métodos de hoy en día, más lo que agregan de novedad para mejorar sus métricas. Por medio de la lectura, se consigue una solución que reduce costos y tiempo de diagnóstico dentro de los padecimientos de tuberculosis y COVID-19 por medio de una clasificación de los embeddings extraídos de la CNN que será utilizada para obtener características de las radiografías.

1. Introducción

Las enfermedades de las vías respiratorias son un reto crucial para la salud pública en todo el mundo. Ejemplo de ello es el COVID-19 que ha evidenciado su repercusión a nivel mundial dado los niveles de mortalidad y la saturación de los sistemas sanitarios, mientras que la tuberculosis continúa siendo una de las infecciones más comunes. Para disminuir las complicaciones, evitar que se propague y optimizar los resultados clínicos, es esencial detectar estas enfermedades a tiempo.

Los análisis de imágenes médicas, por ejemplo las tomografías computarizadas y las radiografías, así como los exámenes de laboratorio, son parte de los métodos tradicionales para hacer diagnósticos. No obstante, la interpretación de estas imágenes necesita una formación especializada y puede estar expuesta a errores humanos, demoras y diferencias en la precisión entre varios expertos. Asimismo, la similitud radiológica entre diferentes enfermedades hace que sea difícil una clasificación rápida y precisa.

En este caso, las técnicas de aprendizaje profundo y visión artificial se ofrecen como una opción para respaldar el diagnóstico médico, ya que facilitan la detección de patrones complejos en las imágenes con rapidez y consistencia. Es por ello que los trabajos revisados demuestran que las redes neuronales convolucionales, los métodos de transferencia de aprendizaje y las técnicas de interpretabilidad como Grad-CAM son las estrategias más empleadas para la detección automática de enfermedades torácicas. No obstante, se observa una falta de estandarización en los conjuntos de datos, la escasez de validaciones cruzadas externas y un uso limitado de bases de datos balanceadas, lo cual limita la generalización clínica de los modelos. Pese a ello, algunos estudios comienzan a abordar estas deficiencias; por ejemplo, Kabir et al. (2024) [6] implementaron un enfoque de destilación de

conocimiento entre modelos profesor–alumno que mejora la capacidad de generalización, mientras que Kaewlek et al. (2023) [9] emplearon una validación multicéntrica con diversas bases de datos públicas, reduciendo el sesgo en la evaluación.

El objetivo de este proyecto es crear un sistema para clasificar imágenes pulmonares con el fin de identificar si hay pulmones sanos, COVID-19 o tuberculosis, y así poder contrastar diferentes métodos de modelado. De esta manera, se podrá establecer cuál es el que tiene una mejor eficacia y mayor aplicabilidad en el área clínica.

Por lo que la posible solución planteada consiste en el desarrollo de un modelo de aprendizaje profundo basado en redes neuronales convolucionales (CNN) que permita clasificar imágenes de tórax y distinguir entre pulmones sanos, COVID-19 y tuberculosis. El sistema seguirá una metodología compuesta por etapas de preprocesamiento, extracción de características, su clasificación e interpretación visual mediante Grad-CAM, con el fin de optimizar la precisión diagnóstica y ofrecer un soporte clínico confiable que reduzca los errores humanos y acelere el proceso de diagnóstico.

2. Planteamiento del Problema

En el ámbito de la salud mundial, las enfermedades respiratorias son cruciales. La tuberculosis sigue siendo persistente en muchas regiones en desarrollo. Por un lado el COVID-19, que redefinió nuestro mundo y cuyas réplicas, más allá de los hospitales, siguen sacudiendo la economía y la sociedad. Aunque son enfermedades distintas, ambas comparten similitudes que podemos explotar: necesitan ser descubiertas a tiempo. Un diagnóstico que llega tarde no es solo una oportunidad perdida; es el detonante casi seguro de complicaciones graves y una brecha de oportunidad para que la enfermedad se propague.

La ruta diagnóstica actual se apoya en tres puntos: la valoración clínica, los resultados de laboratorio y las imágenes que obtenemos del tórax. Las radiografías. Sin embargo, toda esta tecnología converge en un punto crítico y profundamente humano: la interpretación de un profesional. Y aquí, la pericia, aunque inmensa, se enfrenta a sus propios límites. Presentando patrones radiológicos tan parecidos que distinguirlas se convierte de alto riesgo.

Frente a este panorama, la visión por computadora y el aprendizaje profundo no se presentan como una simple herramienta, sino como un cambio. Las redes neuronales convolucionales (CNN) son el punto de esta revolución. Estos algoritmos pueden ser entrenados para detectar patrones sutiles y complejos en las imágenes médicas, detalles que a menudo escapan a la percepción del ojo humano.

3. Justificación

En la actualidad el mundo de la salud ha sido minimizado en estos avances tecnológicos que día con día van mejorando, aunque existen diversas aplicaciones, muy pocas de estas están adaptadas específicamente a las necesidades médicas diversas que estas abarcan. Como bien se menciona [2] la tendencia a el aumento de investigación de estos problemas respiratorios se vio impulsado debido a la situación que vivimos en pandemia. Este modelo busca diseñar una alternativa eficiente y eficaz para poder así generar estos diagnósticos oportunos, con apoyo de un especialista podremos corroborar su validez y así brindar el apoyo a quién lo necesita.

4. Objetivos

4.1. Objetivo General

El objetivo general de esta investigación es:

Crear un modelo basado en visión computacional para clasificar pulmones que estén sanos, afectados por COVID-19 o tuberculosis, con el fin de mejorar los tiempos de diagnóstico y robustecer la toma de decisiones clínicas.

4.2. Objetivos Específicos

1. Recopilar y escoger grupos de imágenes médicas (rayos X) de pulmones sanos, con COVID-19 y con tuberculosis
2. Realizar la limpieza, normalización y preparación de las imágenes.
3. Aplicar un modelo de clasificación basado en redes neuronales convolucionales (CNN) para categorizar imágenes de las tres clases
4. Obtener las métricas de precisión F1-score, recall y curvas ROC.
5. Validar el rendimiento comparando los resultados.

5. Hipótesis

La categorización de imágenes pulmonares en tres grupos (sano, COVID-19 y tuberculosis) con una exactitud y sensibilidad apropiadas se facilita mediante el empleo de modelos de visión artificial fundamentados en redes neuronales convolucionales. Asimismo, el empleo de representaciones intermedias, como vectores de características, en combinación con clasificadores convencionales, puede hacer que el rendimiento sea superior al de un modelo multclasificador, sobre todo cuando se trata de detectar enfermedades críticas.

6. Alcances

- El proyecto se centrará en imágenes médicas (rayos X) de pulmones obtenidas de datasets públicos.
- Se utilizarán técnicas de transfer learning y preprocesamiento estándar en visión artificial (normalización).
- Se valorará el sistema en relación con su rendimiento y se examinará su factibilidad como instrumento de asistencia diagnóstica dentro de un entorno clínico.

7. Limitaciones

- El modelo se limita a un rango pequeño de condiciones: tuberculosis, COVID-19 y pulmones sanos, excluyendo otras enfermedades respiratorias.
- La dependencia de los repositorios públicos introduce un margen de disparidad en la calidad de las imágenes, ya sea por su resolución o por la tecnología utilizada. Factores demográficos de la población de procedencia o datos radiológicos utilizados, lo que podría reducir la habilidad del sistema para generalizar.
- No se prevé, ni la validación en un ambiente real de hospital o clínica. consecución de certificaciones médicas, dado que la naturaleza del proyecto es Limita a fines exploratorios y al ámbito académico.

8. Trabajos Relacionados

Dentro de las investigaciones que se encontraron las principales problemáticas radican en inconsistencia dentro de la calidad de los datos ya que las imágenes tienden a ser difíciles de relacionarse a la enfermedad dado que son tan sutiles los rasgos que la diferencian, aunado a eso el desarrollo de un sistema que logre clasificarlas es complejo ya que al ser un órgano tan grande presenta un gran catálogo de enfermedades por ello lo que se llega a notar en estos trabajos es que cada uno se centra en una sola enfermedad y sus variantes de la misma.

Principalmente estos trabajos manifiestan el uso de “ChestX-ray8” el cual cuenta con una gran cantidad de datos de radiografías basándose en 8 enfermedades predominantes en esta área [1].

Como dato adicional importante hay que mencionar que los proyectos relacionados a estas clasificaciones suelen utilizar modelos de CNN, sin embargo también encontramos distintos enfoques para garantizar una producción sólida y aumentar la precisión. Uno de ellos es un diseño de un modelo basado en modelos previamente entrenados como lo son los mencionados en la literatura [2],

posteriormente los resultados se combinaron a un vector para poder así dar una predicción final. En este marco de aprendizaje profundo el modelo logró tener un 96.4 % de precisión.

Dentro de la materia se comparó con el rendimiento de aprendizaje híbrido profundo y el aprendizaje híbrido impulsado profundamente con CNN establecidas [4], en donde se llega a observar que los modelos híbridos profundos superaron a CNN. En otro estudio se propuso otro modelo híbrido [5], en donde se transformaron las dimensiones de los datos y utilizaron bloques los cuales ayudarían a cifrar para evitar el sesgo del rendimiento, utilizaron valores aleatorios del conjunto de entrenamiento donde se tuvo una precisión del 97.6 %.

En trabajos más recientes se ha observado una evolución en las técnicas aplicadas al diagnóstico por imágenes torácicas. En el paper de Kabir propusieron un modelo de destilación de conocimiento entre redes neuronales tipo profesor–alumno para la detección de COVID-19, neumonía y tuberculosis, obteniendo métricas de precisión y recall elevadas gracias al uso de datasets variados de Kaggle [6]. De forma similar, con Lei experimentaron con arquitecturas AlexNet, ResNet e InceptionV3, incorporando Grad-CAM para la interpretabilidad del modelo y reportando un incremento significativo en el AUC y el F1-Score [7]. En la misma línea, en la investigación de Hazlett implementaron un enfoque basado en transferencia de aprendizaje utilizando diferentes bases de datos, logrando un rendimiento alto en precisión y exactitud [8].

Por su parte, Kaewlek et al. (2023) realizaron una clasificación de neumonía, tuberculosis y COVID-19 mediante tomografías computarizadas empleando redes ResNet y DCNN, con una exactitud de hasta 0.966 y un F1-Score de 0.931 [9]. Finalmente, Constantinou et al. (2023) desarrollaron un sistema de clasificación apoyado en ResNet y DenseNet con un 96 % de precisión sobre el conjunto de datos COVID-QU [11]. En conjunto, estos cinco trabajos recientes consolidan el uso de modelos de aprendizaje profundo en el análisis de imágenes pulmonares, reforzando la tendencia hacia el uso de redes convolucionales avanzadas y la incorporación de técnicas de interpretabilidad visual para apoyar el diagnóstico médico.

Como mención, este tipo de experimentos se han estado realizando, pero cada uno de ellos enfocados en áreas diferentes tanto del órgano como en el enfoque de la enfermedad. Por consiguiente, se busca tener el mejor resultado posible considerando el error que se presenta a lo largo de estos procesamientos automáticos.

8.1. Taxonomía y Comparativa

Tabla 1: Resumen de investigaciones sobre detección de enfermedades torácicas.

Autor(es)	Título	Modelo(s)	Hardware / Software	Resultados (Métricas)	Dataset(s)
Hazlett, A., et al. (2025)	Detección de Enfermedades Torácicas en Imágenes de Rayos X Usando un Método de Clasificación de Aprendizaje Profundo [8]	CNNs pre-entrenadas, Transfer Learning, Grad-CAM	Google Co-lab	Alta exactitud, precisión, recall y F1 para 4 clases	Lungs Disease Dataset, COVIDx dataset 57,111 imagenes

Autor(es)	Título	Modelo(s)	Hardware / Software	Resultados (Métricas)	Dataset(s)
Titipong Kaewlek, et al. (2023)	Clasificación de Neumonía, Tuberculosis y COVID-19 en Imágenes de Tomografía Computarizada usando Aprendizaje Profundo [9]	AlexNet, GoogleNet, ResNet, DCNN	Google Colab Pro (GPU: Tesla P100)	ResNet: Exactitud 0.966, F1-Score 0.931	Compilación de 4 BBDD (Kaggle, Github, etc.)
Constantinou, M., et al. (2023)	Clasificación de COVID-19 en Imágenes de Rayos X de Tórax Usando Métodos de Aprendizaje Profundo [11]	ResNet50/101, DenseNet121/169, InceptionV3	Python, TensorFlow, Keras en CPU (AMD Ryzen 5600X)	ResNet101: Precisión, Recall y Exactitud del 96 %	COVID-QU Dataset (BIMCV-COVID19+, etc.)
Rudi K., et al. (2024)	Detección de Tuberculosis basada en Imágenes de Rayos X de Pulmón Usando Redes Neuronales Convolucionales (CNN) [12]	CNN personalizada (3 capas conv., 2 capas densas)	No especificado	No se reportan métricas numéricas	Dataset del estudio de Rahman et al.
Kabir, M. M., et al. (2024)	Detección de COVID-19, neumonía y tuberculosis a partir de radiografías mediante destilación de conocimiento impulsada por IA [6]	CNNs con Destilación de Conocimiento (Profesor-Alumno)	No especificado	Precisión 96.08 %, Recall 97 %, Exactitud 94 %	Varios de Kaggle (COVID-19, Neumonía, Tuberculosis)

Autor(es)	Título	Modelo(s)	Hardware / Software	Resultados (Métricas)	Dataset(s)
Zaid Mustafa, Heba Nsour (2023)	Uso de Técnicas de Visión Computacional para Detectar Automáticamente Anormalidades en Radiografías de Tórax [14]	YOLO v8 (modificado para clasificación)	TensorFlow	Clasifica infecciones, TB y nódulos (sin métricas numéricas)	No especificado

9. Marco Teórico

Las afecciones respiratorias, como el COVID-19 y tuberculosis representan un gran desafío significativo para la salud en general, esto es causado por tener un impacto directo en la mortalidad de la población lo que puede desencadenar saturación en los sistemas de atención médica. La detección temprana de estas enfermedades es esencial para prevenir complicaciones, reducir la proliferación de la enfermedad y mejorar los resultados clínicos de los pacientes.


Tradicionalmente, el diagnóstico se realiza mediante la combinación de análisis clínicos como lo son las pruebas de laboratorio, imágenes médicas principalmente tomografías y radiografías computarizadas. Sin embargo, la interpretación de estas imágenes requiere de experiencia especializada que puede estar sujeta a errores, fatiga y variabilidad de los expertos. Igualmente a la similitud radiológica entre las distintas enfermedades pulmonares puede dificultar la clasificación rápida y precisa.

Una variedad de estudios han demostrado la eficiencia de los modelos basados en redes neuronales convolucionales (CNN) y enfoques híbridos de aprendizaje profundo para la clasificación de enfermedades respiratorias a partir de imágenes.


El progreso de sistemas que incorporen varias patologías respiratorias y sean capaces de distinguir entre pulmones sanos y enfermos supone un avance significativo para mejorar el tiempo, disminuir los gastos y ofrecer a los pacientes una atención superior, empleando la capacidad de la inteligencia artificial para complementar el trabajo de los especialistas en radiología.

10. Metodología


El algoritmo puede ser gráficamente explicado como se muestra en la figura 1. Donde se visualiza la secuencia de los pasos a realizar.



(a) Leyenda para la primera imagen horizontal (arriba).



(b) Leyenda para la segunda imagen horizontal (medio).



(c) Leyenda para la tercera imagen horizontal (abajo).

Figura 1: Esta es la leyenda principal que describe las tres imágenes apiladas.

1. **Adquisición de los datos:** Se comenzó con la recopilación de imágenes de rayos X de pulmones provenientes de bases de datos públicas. Cada imagen fue etiquetada según su condición: tuberculosis, COVID-19 o saludable. Se utilizaron conjuntos de datos reconocidos como “COVID-19 Radiography Database”, “Chest X-Ray (Covid-19 & Pneumonia)” y “Tuberculosis (TB) Chest X-ray Database” de Kaggle para construir una base de información robusta sobre la cual se desarrolló el flujo de trabajo.

A partir de los conjuntos de datos se obtuvieron imágenes representativas de las distintas clases, como se muestra a continuación en la figura 2.




Figura 2: Ejemplos de las imágenes recopiladas antes de su segmentación.

2. **Segmentación de la Zona Torácica (Pulmones):** La segmentación de la región pulmonar se efectuó manualmente, delimitando la zona de los pulmones en cada imagen torácica. Este procedimiento permitió eliminar las estructuras ajenas al análisis y asegurar una mayor precisión en la identificación de la zona de interés, especialmente en casos donde los métodos automáticos no resultaban confiables.




Figura 3: Ejemplos de las imágenes recopiladas después de su segmentación.

3. **Preprocesamiento de imágenes:** Una vez recopilados los datos, se aplicó un preprocesamiento para estandarizar la consistencia y calidad de las imágenes de entrada:
 - **Estandarización de formato y resolución:** Cada imagen fue redimensionado a un tamaño fijo de 224×224 píxeles. Este tamaño se seleccionó por su compatibilidad con muchas redes neuronales convolucionales preentrenadas.
 - **Conversión a escala de grises:** Para reducir la complejidad computacional y eliminar variables de color irrelevantes en radiografías, todas las imágenes se convirtieron a un solo canal.
 - **Normalización de intensidad (Expansión de contraste):** Se aplicó una normalización Min-Max a nivel de imagen. Los valores de píxeles de cada imagen se escalaron para que ocuparan todo el rango dinámico posible de 8 bits [0, 255]. Esto estandarizó el contraste y brillo entre imágenes, corrigiendo posibles variaciones de exposición en los escaneos originales.
 - **Almacenamiento y segregación:** Las imágenes procesadas se guardaron en un nuevo directorio (`dataset_limpio`), conservando la estructura de carpetas original que separaba las clases (**COVID-19**, **Tuberculosis**, **Saludable**). Finalmente se realizó un registro de cualquier imagen que fallara durante el proceso.
4. **Estratificación y División de datos:** El conjunto de datos preprocesado (`dataset_limpio`) se dividió en tres subconjuntos independientes: entrenamiento (70 %), validación (20 %) y prueba (10 %).

- **Estratificación:** Para asegurar que todas las clases (COVID-19, Tuberculosis, Saludable) estuvieran representadas equitativamente en cada subconjunto, la división se realizó por clase. Se aplicó `random.shuffle` a las imágenes dentro de cada clase antes de asignarlas a un conjunto.

5. **Extracción de Características (Embeddings):** En lugar de entrenar una CNN desde cero, se empleó una estrategia de *transfer learning* para generar vectores de características.

- **Modelo Base:** Se utilizó **MobileNetV2**, preentrenado en ImageNet, como un extractor de características de propósito general. Se cargó el modelo con `include_top=False`, descartando la capa de clasificación original de 1000 clases.
- **Congelación de Pesos:** Los pesos del modelo base se congelaron (`base_model.trainable = False`), asegurando que solo se utilizara su conocimiento aprendido para la extracción y no se modificara.
- **Generación del Vector:** La salida del modelo base (un mapa de características 4D) se pasó a través de una capa `GlobalAveragePooling2D`. Esto condensó el mapa en un vector de características 1D (embedding) de 1280 dimensiones, capturando la información semántica de la imagen.
- **Generador de Datos:** Se utilizó `ImageDataGenerator` de Keras para cargar las imágenes de los directorios divididos. Este generador aplicó la función de preprocesamiento específica de MobileNetV2 (`preprocess_input`), que escaló los píxeles al rango `[-1, 1]`, y convirtió automáticamente las imágenes de escala de grises a 3 canales para que coincidieran con la entrada esperada por el modelo.
- **Exportación:** Se utilizó el modelo extractor final para predecir (`.predict()`) sobre los generadores de entrenamiento, validación y prueba. Los vectores de características resultantes y sus etiquetas se guardaron en archivos CSV (`train_features.csv`, `val_features.csv`, `test_features.csv`) para ser consumidos por los modelos de clasificación.

6. **Clasificación y Evaluación de Paralelización:** Con los embeddings extraídos (vectores de 1280 dimensiones) guardados en archivos CSV, se implementó la rama de clasificación híbrida de la metodología. Se utilizaron tres clasificadores tradicionales: **Support Vector Classifier (SVC)**, **Random Forest (RF)** y **K-Nearest Neighbors (KNN)**.

11. Resultados preliminares

Con el objetivo de evaluar el desempeño del modelo propuesto para la clasificación de radiografías de tórax en tres categorías (COVID-19, tuberculosis y pulmones sanos), se realizaron experimentos utilizando dos configuraciones distintas del conjunto de datos: (1) un subconjunto segmentado manualmente de 1000 imágenes por clase, y (2) un conjunto ampliado de aproximadamente 12 000 imágenes sin segmentación previa.

En ambos casos, las imágenes fueron redimensionadas a 224×224 píxeles y convertidas a escala de grises. Para la extracción de características se empleó la arquitectura *MobileNetV2* mediante un esquema de *Transfer Learning*, congelando sus capas convolucionales y utilizando los *embeddings* resultantes como vectores de características. Dichos vectores se emplearon como entrada para distintos clasificadores tradicionales: Clasificador de Vectores de Soporte (SVC), k-Vecinos Más Cercanos (KNN) y Bosques Aleatorios (Random Forest, RF).

11.1. Experimento con imágenes segmentadas

Al trabajar con el conjunto de 3000 imágenes segmentadas (1000 por clase), los tres clasificadores mostraron un rendimiento elevado. El modelo SVM alcanzó la mayor exactitud con un 0.9768, seguido por Random Forest con 0.9732 y KNN con 0.9411. Las métricas de precisión, *recall* y F1-score se mantuvieron en valores superiores a 0.94 en todas las clases, evidenciando una buena capacidad de discriminación entre categorías.

La comparación entre las métricas de entrenamiento y prueba sugiere que no existe sobreajuste significativo, dado que las diferencias de desempeño fueron menores al 2 % (por ejemplo, Accuracy SVM train = 0.9622 vs. test = 0.9768).

```

--- Resultados SVM ---
Accuracy (SVM): 0.9768
      precision    recall  f1-score   support

      covid        0.95      0.99      0.97       182
      normal        0.99      0.96      0.97       187
      tuberculosis  0.99      0.98      0.99       191

      accuracy          0.98       560
      macro avg        0.98      0.98      0.98       560
      weighted avg     0.98      0.98      0.98       560

--- Resultados Random Forest ---
Accuracy (RF): 0.9732
      precision    recall  f1-score   support

      covid        0.97      0.97      0.97       182
      normal        0.97      0.98      0.98       187
      tuberculosis  0.97      0.97      0.97       191

      accuracy          0.97       560
      macro avg        0.97      0.97      0.97       560
      weighted avg     0.97      0.97      0.97       560

--- Resultados KNN ---
Accuracy (KNN): 0.9411
      precision    recall  f1-score   support

      covid        0.96      0.95      0.96       182
      normal        0.90      0.97      0.93       187
      tuberculosis  0.97      0.90      0.93       191

      accuracy          0.94       560
      macro avg        0.94      0.94      0.94       560
      weighted avg     0.94      0.94      0.94       560

```

Figura 4: Métricas de desempeño de los clasificadores (SVC, KNN y RF) utilizando imágenes segmentadas manualmente.

11.2. Experimento con imágenes sin segmentar

En el conjunto ampliado de aproximadamente 12 000 imágenes sin segmentación, se observó una ligera disminución general en el desempeño. El SVM obtuvo una exactitud de 0.9626, mientras que KNN alcanzó 0.9213 y Random Forest 0.8895. Aunque el modelo SVM mantuvo una alta capacidad de generalización, los demás clasificadores mostraron una mayor diferencia entre entrenamiento y prueba, evidenciando un leve sobreajuste (por ejemplo, RF train = 0.9891 vs. test = 0.8895).

```

--- Resultados SVM ---
Accuracy (SVM): 0.9626
              precision    recall  f1-score   support

      Covid          0.96       0.94       0.95        408
      Normal          0.96       0.98       0.97        529
Tuberculosis          0.97       0.96       0.97        321

 accuracy
macro avg          0.96       0.96       0.96        1258
weighted avg       0.96       0.96       0.96        1258

--- Resultados Random Forest ---
Accuracy (RF): 0.8895
              precision    recall  f1-score   support

      Covid          0.87       0.85       0.86        408
      Normal          0.88       0.95       0.91        529
Tuberculosis          0.94       0.84       0.89        321

 accuracy
macro avg          0.90       0.88       0.89        1258
weighted avg       0.89       0.89       0.89        1258

--- Resultados KNN ---
Accuracy (KNN): 0.9213
              precision    recall  f1-score   support

      Covid          0.94       0.86       0.90        408
      Normal          0.88       0.99       0.93        529
Tuberculosis          0.99       0.89       0.94        321

 accuracy
macro avg          0.94       0.91       0.92        1258
weighted avg       0.93       0.92       0.92        1258

```

Figura 5: Desempeño de los clasificadores (SVC, KNN y RF) utilizando el conjunto de datos sin segmentación.

11.3. Análisis general

Los resultados preliminares indican que la segmentación manual de la región pulmonar contribuye a mejorar el rendimiento de los clasificadores, al eliminar información irrelevante y concentrar el aprendizaje en la zona de interés. Entre los modelos evaluados, SVC con características extraídas mediante MobileNetV2 demostró ser la combinación más eficaz y estable en ambas configuraciones del conjunto de datos.

Los resultados obtenidos refuerzan la relevancia del preprocesamiento y la segmentación en el análisis automatizado de radiografías de tórax, y apuntan a que en trabajo futuro se orientara a dar una mayor explicabilidad de las regiones que distinguen a cada clase por medio de GRAD-CAM.

12. Conclusiones

A partir del análisis del estado del arte, se puede concluir que el uso de técnicas de aprendizaje profundo y visión por computadora representa la tendencia más prometedora en la detección automática de enfermedades respiratorias. Los trabajos revisados demuestran avances importantes en precisión y sensibilidad, aunque persisten limitaciones en cuanto a la estandarización de los conjuntos de datos y la validación externa.

Investigaciones recientes como las referenciadas en [12, 13, 14, 15] han reforzado la importancia de la integración de arquitecturas híbridas, el uso de conjuntos de datos balanceados y la optimización mediante técnicas de aprendizaje auto-supervisado. Estos enfoques buscan superar los problemas de sobreajuste y mejorar la generalización de los modelos ante datos provenientes de distintas poblaciones o equipos de imagenología.

Referencias

- [1] Ortiz-Preciado, A. A., Fernández, J. A. V., & Ochoa-Ruiz, G. *Clasificación de enfermedades del tórax usando aprendizaje profundo y aumento de datos de calidad en el conjunto de datos ChestX-ray8*. Res. Comput. Sci. 2019.
- [2] Meedeniya, D., Kumarasinghe, H., Kolonne, S., Fernando, C., De la Torre Díez, I., & Marques, G. *Chest X-ray analysis empowered with deep learning: A systematic review*. Applied Soft Computing, 126, 109319, 2022. <https://doi.org/10.1016/j.asoc.2022.109319>
- [3] Muthaki, T., Masuk, S. I., Maksud, A., Rafi, M. A. H., & Sakib, N. *An Approach to Detect Cardiomegaly, COVID-19, Pneumonia, Pneumothorax and Tuberculosis from CXR Images Using Ensembles of Deep Learning*. En *2023 26th International Conference on Computer and Information Technology (ICCIT)*, IEEE, diciembre de 2023, pp. 1–6.
- [4] Qaid, T. S., Mazaar, H., Al-Shamri, M. Y. H., Alqahtani, M. S., Raweh, A. A., & Alakwaa, W. *Modelos híbridos de aprendizaje profundo y aprendizaje automático para predecir COVID-19*. Computational Intelligence and Neuroscience, 2021, 2021, 9996737.
- [5] Al-Waisy, A. S., Mohammed, M. A., Al-Fahdawi, S., Maashi, M. S., García-Zapirain, B., Abdulkareem, K. H., Mostafa, S. A., Kumar, N. M., & Le, D. N. *COVID-DeepNet: sistema híbrido multimodal de aprendizaje profundo para mejorar la detección de neumonía por COVID-19 en imágenes de rayos X de tórax*. Computer Systems Science and Engineering, 67, 2409–2429, 2021.
- [6] Kabir, M. M., et al. *Detección de COVID-19, neumonía y tuberculosis a partir de radiografías mediante destilación de conocimiento impulsada por IA*. Heliyon, 2024. Disponible en: <https://doi.org/10.1016/j.heliyon.2024.e26801>
- [7] Lei, Y., et al. *Clasificación de Enfermedades Torácicas en Radiografías de Tórax Impulsada por Aprendizaje Profundo*. arXiv preprint, 2025. Disponible en: <https://arxiv.org/abs/2501.14279>
- [8] Hazlett, A., et al. *Detección de Enfermedades Torácicas en Imágenes de Rayos X Usando un Método de Clasificación de Aprendizaje Profundo*. arXiv preprint, 2025. Disponible en: <https://arxiv.org/abs/2505.22609>
- [9] Kaewlek, T., et al. *Clasificación de Neumonía, Tuberculosis y COVID-19 en Imágenes de Tomografía Computarizada usando Aprendizaje Profundo*. Thai Journal of Information Science, 2023. Disponible en: <https://tis.wu.ac.th/index.php/tis/article/download/6974/675>
- [10] Mwendo, I., et al. *Aprendizaje por Transferencia Profundo para Detectar Covid-19, Neumonía y Tuberculosis usando imágenes CXR – Una Revisión*. arXiv preprint, 2023. Disponible en: <https://arxiv.org/abs/2303.16754>
- [11] Constantinou, M., et al. *Clasificación de COVID-19 en Imágenes de Rayos X de Tórax Usando Métodos de Aprendizaje Profundo*. International Journal of Environmental Research and Public Health, 2023. Disponible en: <https://doi.org/10.3390/ijerph20032035>
- [12] Rudi, K., et al. *Detección de Tuberculosis basada en Imágenes de Rayos X de Pulmón Usando Redes Neuronales Convolucionales (CNN)*. ResearchGate preprint, 2024. Disponible en: <https://www.researchgate.net/publication/386904756>
- [13] Masuk, S. I., et al. *An Approach to Detect Cardiomegaly, COVID-19, Pneumonia, Pneumothorax, and Tuberculosis from CXR Images Using Ensembles of Deep Learning*. ResearchGate preprint, 2023. Disponible en: <https://www.researchgate.net/publication/378372833>
- [14] Mustafa, Z., & Nsour, H. *Uso de Técnicas de Visión Computacional para Detectar Automáticamente Anormalidades en Radiografías de Tórax*. PubMed, 2023. Disponible en: <https://pubmed.ncbi.nlm.nih.gov/37761345/>
- [15] Kumar, S., et al. *A methodical exploration of imaging modalities from the dataset to detection through machine learning paradigms in prominent lung disease diagnosis: a review*. BMC Medical Imaging, 2024. Disponible en: <https://doi.org/10.1186/s12880-024-01192-w>